Homework 5

Jana Poľašková

April 10, 2026

1 Dataset

Rozhodla som si vytvoriť vlastný dataset, aby som ho vedela jednoducho vysvetliť. Vybrala som si klasickú tabulkovú formu, ktorá obsahuje jednoduché logické výrazy. Vygenerovných dát je 10 000. V každom riadku máme 5 hodnôt a vysledný binárny target, ktorý je takto vypočítaný:

$$y = \begin{cases} 2x_1 + x_2 - x_3 + 0.01x_4 + 0x_5 > 0, & \text{if } x_2 \bmod 2 = 0 \\ 2x_1 + x_2 + x_3 + 0.01x_4 + 0x_5 > 0, & \text{otherwise} \end{cases} \tag{1}$$

Výsledna trieda je teda TRUE ak je výraz väčší ako 0, inak FALSE. Hned si môžeme všimnúť niekolko aspektov, ktoré bude zaujimavé skúmať. Hodnota x_5 vôbec neprispieva k finálnej hodnote, takže na túto by sa model mal naučiť vôbec sa nezameriavať. Taktiež hodnota x_4 prispieva iba trošku, model by sa nemal na nu taktiež velmi zameriavať. Očakávam že hodnot x_1 bude najviac dôležitá, pretože ju mám pripočítanú dvojnásobne. Najviac zaujimavé bude skúmať x_3, pretože podla toho či je kladná alebo zaporná bude pomáhať dostať sa bližšie k jednej alebo druhej triede. Toto zaleži od toho či je táto hodnota párna, čo je podla mna celkom netriviálne na zistenie pre model.

	x1	x2	x3	x4	x5	target
0	20	-13	-19	-3	-5	True
1	-6	-12	-14	14	-15	False
2	17	7	-18	-19	-15	True
3	-7	-6	12	18	-19	False
4	15	-8	14	6	-6	True

Figure 1: Ukážka datasetu

Zaujimavý poznatok je že ked som pôvodne mala x_3 hodnotu nastavenú v rovnici že prispieva trojnásobne, model sa nevedel naučiť na testovacích dátach lepšie ako na 65 %.

2 Model

Ako model na skúmanie som si vybrala klasickú neuronovú sieť s následujúcou archutektúrou: 5 → ReLU → 64 → ReLU → 32 → ReLU → 1.

Model som trénovala počas 1400 epoch (dokedy loss klesal). Finálna presnosť je 95.8% na trénovacom a 88.5% na testovacom datasete.

3 Gradient Metóda podla vstupov

Gradientová metóda ukazuje dôležitosť vstupných parametrov pomocou derivácie výstupu modelu podľa vstupu. Pre vstup x je dôležitosť x_i daná výrazom $\frac{\partial f(x)}{\partial x_i}$. Toto vypočitam cez funkciu, ktorá vráti gradient vstupu z 1 vrstvy (x.grad[0]).

Veľkosť gradientu určuje mieru vplyvu parametra na predikciu a znamienko určuje smer tohto vplyvu. Tu by som chcela hlavne pozorovať, ktoré parametre sú ako velmi dôležité a či to sedí s mojími predpokladmi uvedeními vyššie.

3.1 Priemerná aboslútna dôležitosť

Priemernú aboslútnu dôležitosť som výrátala ako priemer pre celý testovací dataset.

Feature	Hodnota
x_1	11.70
x_2	5.65
x_3	4.38
x_4	1.03
x_5	1.05

Table 1: Dôležitosť vstupných parametrov získane gradientovou metódou

Z tabuľky 1 vyplýva, že najväčší vplyv na predikciu modelu má parameter x_1 - čo sedí s mojím pozorovaním. Nasledujú parametre x_2 a x_3. x_4 a x_5 majú výrazne nižší vplyv, čo naznačuje, že model ich pri rozhodovaní využíva len minimálne. Zaujímavé že črta x_5 finálnemu cielu vôbec neprispieva ale model jej stále dáva malú doležitosť. Tieto výsledky sú v súlade s očakávaným správaním modelu.

3.2 Presnosť znamienka

Presnosť znamienka meria, či gradientová metóda správne určuje smer vplyvu črty na výstup modelu. Teda ak znemienko pri gradiente je -, model sa viac priklána k triede 0, ked je + viac sa zas priklána k triede 1.

x_3

Pre tento parameter sme derivovali výstup modelu podľa vstupu x_3, čím sme zisťovali, ako zmena x_3 ovplyvní predikciu modelu.

Výsledna hodnota je približne 0.5, čo naznačuje že metóda nedokáže tento smer spoľahlivo zachytiť a správa sa podobne ako náhodný odhad. Avšak je to pochopitelné, pretože táto hodnota nemusí nutne zaručit výslednú predikciu.

x_1

Derivácia podľa x_1 vyjadruje, ako citlivý je výstup modelu na zmenu tohto parametra.

Tu sa očakáva vždy kladný smer vplyvu, keďže v generujúcej funkcii vystupuje s kladným násobením 2. Výsledok je 0.9, čo potvrzuje túto teoriu.

4 LIME

LIME vysvetľuje predikciu modelu lokálne tak, že okolo daného vstupu vytvorí jednoduchý lineárny model, ktorý aproximuje správanie pôvodného modelu.

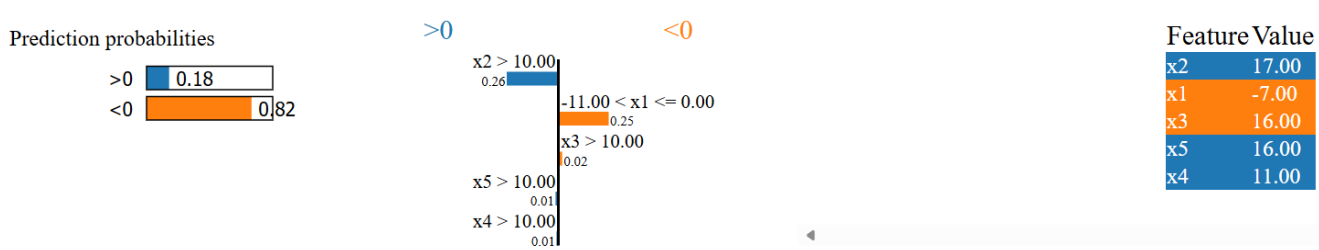

Figure 2: Ukážka LIME na príklade na správnej predikcií

Na príklade 2 vidíme, že model prikladá najväčšiu váhu x_2 a x_3. Črta x_2 má záporný vplyv, zatiaľ čo x_3 je síce kladná, ale model správne rozhodol, že keďže je párna, výsledok bude smerovať k zápornej triede.

Zaujímavé sú intervaly, ktoré sa model rozhodol použiť. Napríklad pre x_1 sa model rozhodol, že ak je hodnota v intervale $(-11, 0]$, prispieva k zápornému výsledku. Horná hranica vyzerá ako správny predpoklad, avšak dolná hranica je menej intuitívna.

Pre x_2 sa model rozhodol, že ak je hodnota väčšia ako 10, prispieva ku kladnej predikcii, čo je tiež pomerne rozumný predpoklad.

Pre x_3 je to však zaujímavé, pretože model sa rozhodol, že ak je hodnota väčšia ako 10, prispieva k zápornej triede. Toto síce v danom prípade platí, avšak nejde o všeobecné pravidlo a neplatí to pre všetky vstupy.

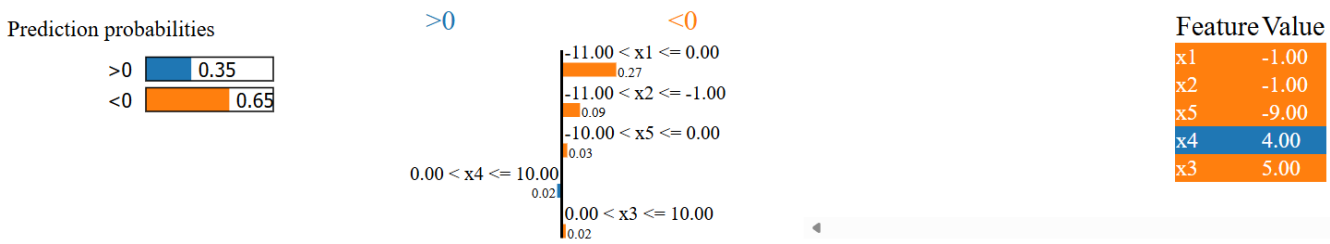

Figure 3: Ukážka LIME na príklade na NEsprávnej predikcií

Tu na príklade 3 vidíme aj situáciu, kde model predikoval nesprávne. Výsledná hodnota rovnice je približne $8 > 0$, avšak model sa tesne rozhodol pre triedu < 0.

Model pri rozhodovaní kládol najväčší dôraz na x_1 a x_2, ktoré sú síce záporné, ale ich vplyv je pomerne malý. Hodnota x_3, ktorá je nepárna a mala by teda prispievať kladne, má podľa modelu len veľmi malý význam, dokonca menší ako x_5, ktorý by pritom nema žiadny vplyv na vysledok.

Zaujímavé je aj to, že črta x_4, hoci má malú nepodstatnu hodnotu, vykazuje väčší vplyv ako x_3.

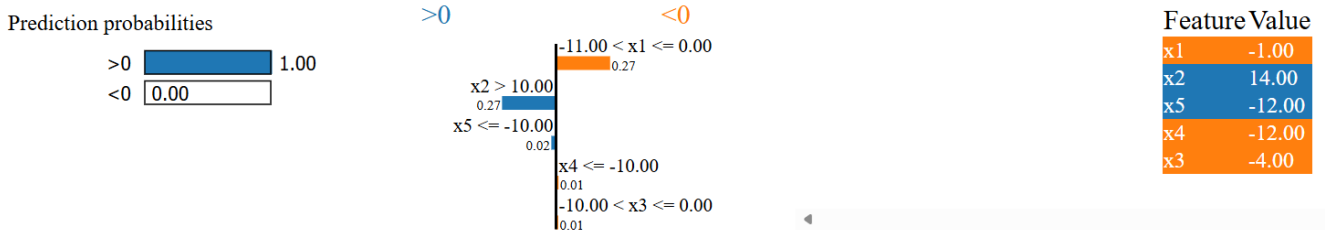

Figure 4: Ukážka LIME na príklade na správnej predikcií

Tu na príklade 4 vidime, že model určil výsledok správne, avšak pripísal význam najmä črtám x_1 a x_2. Je pravda, že tieto dve črty samy o sebe naznačujú, že výsledok má byť väčší ako nula, avšak x_3, ktorá má v tomto prípade kladný príspevok (je párna a zároveň záporná, čím sa jej efekt mení na kladný), dostala len veľmi malú váhu, dokonca menšiu ako náhodný šumy x_5 a x_4.

Chápem to tak, že model má problém správne interpretovať vplyv x_3 a môže byť jej správaním čiastočne zmätený.

5 SHAP

Metóda skúma, ako veľmi a akým smerom každá vstupná premenná ovplyvňuje výslednú predikciu.

Na implementáciu som použila knižnicu shap. Vtejto knižnici graf zobrazuje, ako jednotlivé premenné posúvajú predikciu od priemernej hodnoty smerom k výsledku, pričom farba označuje smer vplyvu a veľkosť jeho intenzitu.

Na grafe 5 vidíme, že model začína od priemernej hodnoty predikcie (base value), ktorá je približne 0.59, avšak po zohľadnení jednotlivých premien sa výsledná hodnota zníži takmer na 0. Najväčší záporný príspevok majú premenne x_1 a x_2, zatiaľ čo x_3 pôsobí opačne, ale jej vplyv nestačí na zmenu výslednej predikcie. Hodnota x_3 v tomto príklade posobí kladne (je párna takže bude mat mínus znamienko ale už jedno má, ku koncu bude kladná), takže je správne tvrdit, že posúva bližšie k triede 1. (> 0)

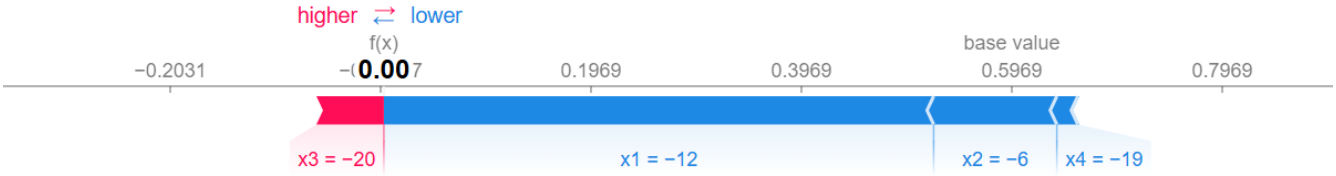

Figure 5: Ukážka SHAP na príklade na správnej predikcií, Predikcia: $f(x) < 0$

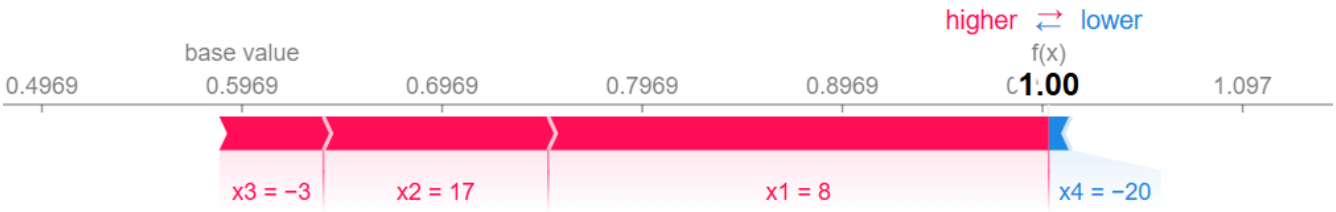

Figure 6: Ukážka SHAP na príklade na správnej predikcií, Predikcia: $f(x) > 0$

Na obrázku 6 vidíme, že premenné x_1 a x_2 majú dominantný pozitívny vplyv, ktorý výrazne zvyšuje predikciu až k hodnote 1. Hoci x_4 (šum) pôsobí opačne, jej vplyv je malý a nedokáže ovplyvniť výsledné rozhodnutie modelu.

Je dobré, že ani na jednom grafe metódy SHAP nepozorujem premennú x_5 ktorá je čisto iba dosadená ako šum. Tieto výsledky sú v súlade s očakávaním.